BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM

TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP.HỒ CHÍ MINH

BÁO CÁO HỌC MÁY

ĐỀ TÀI: DỰ ĐOÁN KHẢ NĂNG VỠ NỢ CỦA KHÁCH HÀNG BẰNG CÁC MÔ HÌNH HỌC MÁY TRÊN BỘ DỮ LIỆU LOAN DEFAULT

Nhóm thực hiện: **Nhóm 2**

Lớp học phần: **DAT704_2511_1_D03**

GVHD: **Vương Trọng Nhân**

TP.HCM, ngày 11 tháng 1 năm 2026

BẢNG PHÂN CHIA CÔNG VIỆC NHÓM 2

STT ở lớp	Họ và tên	Công việc	Mức độ hoàn thành
31	Võ Thị Vân Thư	Code kết quả thực nghiệm + báo cáo chương 5,6	100%
5	Nguyễn Đoàn Nguyệt Hà	Code xử lí dữ liệu + báo cáo chương 3	100%
22	Nguyễn Thị Yến Như	Code xây dựng, huấn luyện mô hình dự đoán + báo cáo chương 4	100%
18	Đặng Hồng Nguyệt	Code giải thích bằng shap + báo cáo chương 5,6	100%
6	Nguyễn Bùi Minh Hằng	Code xây dựng, huấn luyện mô hình dự đoán + báo cáo chương 4	100%
26	Võ Hồng Quyên	Code tải dữ liệu, EDA + báo cáo chương 1,2	100%

MỤC LỤC

I. GIỚI THIỆU BÀI TOÁN 5
1.1. Bối cảnh nghiên cứu 5
1.2. Cơ sở lý thuyết liên quan 5
1.2.1. Rủi ro tín dụng và vỡ nợ 5
1.2.2. Bài toán dự đoán vỡ nợ trong học máy 5
1.2.3. Các thuật toán học máy sử dụng 6
1.2.4. Các chỉ số đánh giá mô hình 7
1.2.5. Giải thích mô hình (Explainable AI – XAI) 7
1.3. Lý do chọn đề tài 8
1.4. Mục tiêu nghiên cứu 8
1.5. Phạm vi và đối tượng nghiên cứu 8
1.5.1. Đối tượng nghiên cứu 8
1.5.2. Phạm vi nghiên cứu 9
II. TỔNG QUAN VỀ TẬP DỮ LIỆU 9
2.1. Nguồn dữ liệu 9
2.2. Khai báo thư viện và tải dữ liệu 9
2.3. Quy mô dữ liệu 10
2.4. Mô tả các thuộc tính 10
2.5. Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) 12
2.5.1. Kiểm tra dữ liệu ban đầu 12
2.5.2. Phân bố biến mục tiêu 13
III. QUY TRÌNH XỬ LÍ DỮ LIỆU 14
3.1. Xóa cột không cần thiết 14
3.2. Mã hóa biến phân loại 14
3.3. Chia tập dữ liệu 15
3.4. Chuẩn hóa dữ liệu 16
3.5. Xử lý mất cân bằng dữ liệu 16

IV. XÂY DỰNG, HUẤN LUYỆN MÔ HÌNH DỰ ĐOÁN 17
4.1. Quy trình xây dựng mô hình dự đoán vỡ nợ 17
4.2. Khởi tạo và huấn luyện mô hình 17
4.3. Dự đoán nhãn vỡ nợ 19
V. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ 20
5.1. Minh họa kết quả dự đoán 20
5.2. Đánh giá mô hình 24
5.3. Giải thích mô hình Logistic Regression bằng SHAP(XAI) 27
VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 29
6.1. Kết luận 29
6.2. Hướng phát triển 30
DANH MỤC TÀI LIỆU THAM KHẢO 31

I. GIỚI THIỆU BÀI TOÁN

1.1. Bối cảnh nghiên cứu

Trong bối cảnh kinh tế số phát triển, hoạt động vay tiêu dùng và tín dụng cá nhân mở rộng nhanh chóng, giúp khách hàng tiếp cận vốn dễ dàng qua ngân hàng số, ứng dụng tài chính và fintech. Tuy nhiên, sự tiện lợi này cũng đi kèm rủi ro, khi biến động thu nhập, việc làm, sức khỏe hay môi trường kinh tế có thể khiến khách hàng mất khả năng thanh toán, ảnh hưởng đến tính thanh khoản và ổn định hệ thống ngân hàng.

Các phương pháp đánh giá tín dụng truyền thống dựa trên quy tắc tuyến tính và ngưỡng cố định thường không đủ linh hoạt để phản ánh các mối quan hệ phi tuyến trong hành vi tài chính. Học máy nổi lên như một công cụ hiệu quả, khai thác lịch sử tín dụng, đặc điểm nhân khẩu học và hành vi tài chính để dự đoán xác suất vỡ nợ chủ động, nâng cao độ chính xác và hỗ trợ ngân hàng xây dựng chiến lược cho vay tối ưu, cân bằng lợi nhuận và an toàn hệ thống.

1.2. Cơ sở lý thuyết liên quan

1.2.1. Rủi ro tín dụng và vỡ nợ

Rủi ro tín dụng là khả năng người vay không thực hiện đầy đủ nghĩa vụ trả nợ gốc và lãi đúng hạn theo cam kết với ngân hàng. Trong hoạt động tín dụng, rủi ro tín dụng là loại rủi ro lớn nhất và có tác động trực tiếp đến lợi nhuận cũng như sự ổn định tài chính của ngân hàng.

Vỡ nợ xảy ra khi khách hàng mất khả năng chi trả do thu nhập suy giảm, thất nghiệp hoặc biến động kinh tế, hoặc cố ý không thực hiện nghĩa vụ trả nợ

Việc gia tăng các khoản vay vỡ nợ dẫn đến nợ xấu, buộc ngân hàng phải trích lập dự phòng rủi ro lớn, làm suy giảm lợi nhuận, ảnh hưởng đến tính thanh khoản và hệ số an toàn vốn (CAR).

1.2.2. Bài toán dự đoán vỡ nợ trong học máy

Bài toán dự đoán khả năng vỡ nợ của khách hàng được mô hình hóa như một bài toán phân loại nhị phân, trong đó:

- Đầu vào (x): các đặc trưng liên quan đến khách hàng (tuổi, thu nhập, điểm tín dụng, lịch sử vay, …)
- Đầu ra (y):

  + 0: Khách hàng không vỡ nợ

  + 1: Khách hàng có khả năng vỡ nợ

Mục tiêu của mô hình là ước lượng xác suất vỡ nợ, từ đó hỗ trợ ngân hàng trong việc ra quyết định phê duyệt, điều chỉnh hạn mức hoặc áp dụng các biện pháp kiểm soát rủi ro phù hợp.

1.2.3. Các thuật toán học máy sử dụng

Trong nghiên cứu, ba thuật toán học máy giám sát phổ biến được sử dụng để dự đoán khả năng vỡ nợ của khách hàng: Logistic Regression, Random Forest và XGBoost. Việc lựa chọn ba mô hình này nhằm so sánh hiệu quả giữa mô hình tuyến tính truyền thống và các thuật toán phi tuyến mạnh mẽ, đồng thời đảm bảo khả năng giải thích và ứng dụng thực tiễn trong lĩnh vực tín dụng.

1. Logistic Regression

Logistic Regression là mô hình phân loại tuyến tính, dùng để dự đoán xác suất xảy ra một sự kiện nhị phân. Trong bài toán tín dụng, mô hình dự đoán khả năng vỡ nợ dựa trên các đặc trưng tài chính, nhân khẩu học và hành vi thanh toán.

Ưu điểm:

- Triển khai dễ dàng, tốc độ huấn luyện nhanh và dễ kiểm soát.
- Cho phép ước lượng trực tiếp xác suất vỡ nợ, hỗ trợ quyết định phê duyệt khoản vay, lãi suất và cảnh báo rủi ro.
- Minh bạch, dễ giải thích, phù hợp yêu cầu quản trị rủi ro và ra quyết định trong ngân hàng.

Hạn chế:

- Khó mô hình hóa các mối quan hệ phi tuyến phức tạp giữa các đặc trưng.
- Bỏ sót thông tin quan trọng nếu dữ liệu có nhiều tương tác phi tuyến.

2. Random Forest

Random Forest là thuật toán tổ hợp dựa trên nhiều cây quyết định. Mỗi cây học từ mẫu dữ liệu ngẫu nhiên và đưa ra dự đoán riêng; kết quả cuối cùng được xác định bằng cơ chế bỏ phiếu đa số.

Ưu điểm:

- Mô hình hóa tốt các quan hệ phi tuyến, phát hiện mẫu phức tạp trong dữ liệu.
- Ít bị overfitting hơn cây quyết định đơn nhờ cơ chế bootstrap và chọn ngẫu nhiên các đặc trưng.
- Hoạt động hiệu quả với dữ liệu nhiều chiều, nhiễu, đặc biệt phù hợp bài toán tín dụng.

Hạn chế:

- Khó giải thích trực tiếp như Logistic Regression.
- Chi phí tính toán cao hơn, đặc biệt khi số lượng cây lớn hoặc dữ liệu lớn.

3. XGBoost

XGBoost (Extreme Gradient Boosting) là thuật toán boosting dựa trên gradient descent, tối ưu hiệu suất dự đoán. Mỗi cây mới học từ sai số của các cây trước để cải thiện độ chính xác tổng thể.

Ưu điểm:

- Tối ưu hóa sai số tổng thể, học tốt các quan sát khó phân loại.

- Hiệu quả cao với dữ liệu lớn, phức tạp và mất cân bằng.
- Kiểm soát overfitting tốt nhờ regularization và pruning.

Hạn chế:

- Cần tinh chỉnh tham số cẩn thận (learning rate, max_depth, n_estimators, scale_pos_weight…).
- Giải thích kém hơn Logistic Regression; cần kết hợp SHAP hoặc LIME để đánh giá tầm quan trọng của biến.

1.2.4. Các chỉ số đánh giá mô hình

Trong bài toán dự đoán vỡ nợ, dữ liệu thường mất cân bằng, ví dụ số khách hàng không vỡ nợ chiếm đa số, trong khi số khách hàng vỡ nợ chiếm tỷ lệ nhỏ. Vì vậy, chỉ dựa vào Accuracy là chưa đủ, cần kết hợp nhiều chỉ số để đánh giá toàn diện.

1. ROC – AUC

- ROC (Receiver Operating Characteristic) thể hiện khả năng mô hình phân biệt giữa khách hàng vỡ nợ và không vỡ nợ.
- AUC (Area Under Curve) đo hiệu quả tổng thể của mô hình; giá trị càng gần 1, mô hình càng phân biệt tốt hai lớp.

2. Precision – Recall

- *Precision:* Tỷ lệ các khách hàng được mô hình dự đoán là vỡ nợ mà thực tế cũng vỡ nợ. Chỉ số này phản ánh mức độ chính xác của cảnh báo rủi ro.
- *Recall (Sensitivity):* Tỷ lệ khách hàng thực sự vỡ nợ được mô hình phát hiện. Trong tín dụng, Recall cao giúp giảm nguy cơ bỏ sót khách hàng rủi ro, tránh tổn thất tài chính.

Trong bài toán tín dụng, bỏ sót khách hàng vỡ nợ (False Negative) gây rủi ro lớn hơn việc cảnh báo dư thừa (False Positive), nên Recall thường được ưu tiên.

3. F1-Score

- Là trung bình hài hòa của Precision và Recall, giúp đánh giá cân bằng giữa độ chính xác và độ nhạy của mô hình.
- F1-score càng cao, mô hình càng đáng tin cậy trong việc nhận diện khách hàng rủi ro.

1.2.5. Giải thích mô hình (Explainable AI – XAI)

Trong lĩnh vực tài chính, tính minh bạch của mô hình là yêu cầu quan trọng nhằm giải thích lý do một khách hàng bị đánh giá có rủi ro vỡ nợ cao. Do đó, nghiên cứu áp dụng phương pháp Explainable AI (XAI), cụ thể là SHAP (SHapley Additive exPlanations).

SHAP dựa trên lý thuyết giá trị Shapley trong trò chơi hợp tác, cho phép đo lường mức độ đóng góp của từng đặc trưng vào kết quả dự đoán của mô hình. Việc sử dụng SHAP giúp làm rõ

các yếu tố ảnh hưởng đến khả năng vỡ nợ của khách hàng, từ đó nâng cao tính minh bạch và khả năng ứng dụng mô hình trong thực tiễn tài chính – ngân hàng.

1.3. Lý do chọn đề tài

Đề tài dự đoán khả năng vỡ nợ của khách hàng được lựa chọn nhờ ý nghĩa thực tiễn cao và chất lượng dữ liệu nghiên cứu. Bộ dữ liệu gồm hơn 255.000 bản ghi, phản ánh toàn diện hành vi tín dụng, cho phép huấn luyện các thuật toán học máy phức tạp, nâng cao độ tin cậy và khả năng tổng quát hóa của mô hình.

Vỡ nợ tín dụng là bài toán trọng tâm trong quản trị rủi ro tài chính, nhưng các phương pháp truyền thống gặp hạn chế khi xử lý dữ liệu lớn và các mối quan hệ phi tuyến giữa đặc trưng khách hàng. Do đó, đề tài tập trung ứng dụng học máy kết hợp phương pháp giải thích mô hình (XAI), vừa nâng cao hiệu quả dự đoán, vừa đảm bảo minh bạch và khả năng ứng dụng trong quyết định tín dụng. Kết quả nghiên cứu mang cả giá trị học thuật và thực tiễn, hỗ trợ các tổ chức tài chính cải thiện chất lượng phê duyệt tín dụng một cách chính xác và công bằng.

1.4. Mục tiêu nghiên cứu

Mục tiêu của đề tài là xây dựng và đánh giá mô hình dự đoán khả năng vỡ nợ của khách hàng dựa trên dữ liệu lịch sử tín dụng, sử dụng các thuật toán học máy như Logistic Regression, Random Forest và XGBoost, nhằm hỗ trợ các tổ chức tài chính nâng cao hiệu quả quản trị rủi ro và chất lượng ra quyết định cho vay.

Nghiên cứu phân tích đặc điểm dữ liệu Loan Default, xác định biến mục tiêu và các biến ảnh hưởng đến rủi ro vỡ nợ, tiến hành tiền xử lý dữ liệu và huấn luyện mô hình. Hiệu suất mô hình được đánh giá bằng các chỉ số phù hợp với dữ liệu mất cân bằng (ROC-AUC, Precision–Recall), đồng thời áp dụng SHAP để minh bạch hóa tác động của từng biến.

Qua đó, đề tài vừa kiểm chứng hiệu quả học máy trong dự đoán vỡ nợ, vừa xây dựng quy trình phân tích dữ liệu tín dụng thực tiễn, làm nền tảng tham khảo cho các hệ thống chấm điểm tín dụng trong ngân hàng và Fintech.

1.5. Phạm vi và đối tượng nghiên cứu

1.5.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là khả năng vỡ nợ của khách hàng vay vốn, được biểu diễn thông qua biến mục tiêu Default trong tập dữ liệu Loan Default. Bên cạnh đó, đề tài tập trung phân tích mối quan hệ giữa khả năng vỡ nợ và các đặc trưng liên quan đến:

- Thông tin nhân khẩu học của khách hàng.
- Tình trạng tài chính và thu nhập.
- Lịch sử tín dụng và đặc điểm khoản vay.

1.5.2. Phạm vi nghiên cứu

Về dữ liệu: Sử dụng tập dữ liệu Loan Default với hơn 255.000 bản ghi, phản ánh lịch sử tín dụng của khách hàng vay vốn.

Về phương pháp: Áp dụng các thuật toán học máy có giám sát cho bài toán phân loại nhị phân; không đi sâu vào các mô hình học sâu phức tạp hoặc dữ liệu thời gian thực.

Về nội dung: Tập trung vào dự đoán khả năng vỡ nợ tại thời điểm cấp tín dụng, chưa xét đến các yếu tố vĩ mô hoặc biến động kinh tế theo chuỗi thời gian.

Về ứng dụng: Kết quả nghiên cứu mang tính minh họa và định hướng, phục vụ mục đích học tập và nghiên cứu, chưa triển khai trong môi trường vận hành thực tế của ngân hàng.

II. TỔNG QUAN VỀ TẬP DỮ LIỆU

2.1. Nguồn dữ liệu

Nghiên cứu sử dụng bộ dữ liệu Loan Default từ nền tảng Kaggle, mô phỏng các giao dịch tín dụng thực tế với thông tin về đặc điểm khách hàng, khoản vay và trạng thái thanh toán. Với cấu trúc đa chiều và quy mô lớn, bộ dữ liệu tạo nền tảng thực nghiệm để xây dựng, huấn luyện và đánh giá các mô hình học máy dự báo rủi ro tín dụng, phục vụ cả nghiên cứu học thuật và ứng dụng thực tiễn trong lĩnh vực tài chính – ngân hàng.

2.2. Khai báo thư viện và tải dữ liệu

Trong bước đầu tiên, nhóm tiến hành khai báo các thư viện cần thiết để phục vụ cho quá trình phân tích dữ liệu và xây dựng mô hình học máy.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.linear_model import LogisticRegression
from sklearn.utils.class_weight import compute_class_weight
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix
from xgboost import XGBClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score, roc_curve, confusion_matrix

import shap
import warnings
warnings.filterwarnings('ignore')
%matplotlib inline
```

Sau đó, tập dữ liệu được tải từ Google Drive và đọc vào dưới dạng DataFrame để sử dụng trong môi trường Google Colab cho các bước xử lý tiếp theo.

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Mounted at /content/drive
```

```
df = pd.read_csv("/content/drive/MyDrive/ML/Loan_default.csv")
```

2.3. Quy mô dữ liệu

Bộ dữ liệu có quy mô lớn, đảm bảo tính đại diện và khả năng tổng quát hóa của các mô hình học máy được xây dựng. Cụ thể, tập dữ liệu bao gồm 255.347 bản ghi, tương ứng với hơn 250 nghìn hồ sơ vay vốn của khách hàng khác nhau.

Về mặt cấu trúc, dữ liệu gồm 18 thuộc tính, trong đó:

- 17 thuộc tính đầu vào (features) mô tả đa chiều thông tin liên quan đến khách hàng và khoản vay
- Một biến mục tiêu (target variable) có tên là Default, được biểu diễn dưới dạng nhị phân:

  + *Default = 0:* Khách hàng thanh toán đúng hạn

  + *Default = 1:* Khách hàng vỡ nợ hoặc không hoàn thành nghĩa vụ tài chính

Biến mục tiêu này đóng vai trò là nhãn dữ liệu, giúp mô hình học cách phân biệt giữa nhóm khách hàng có rủi ro tín dụng thấp và nhóm khách hàng tiềm ẩn nguy cơ vỡ nợ cao.

```
# Kiểm tra thông tin tổng quát
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 255347 entries, 0 to 255346
Data columns (total 18 columns):
 #   Column           Non-Null Count   Dtype  
---  ------           --------------   -----  
 0   LoanID           255347 non-null  object 
 1   Age              255347 non-null  int64  
 2   Income           255347 non-null  int64  
 3   LoanAmount       255347 non-null  int64  
 4   CreditScore      255347 non-null  int64  
 5   MonthsEmployed   255347 non-null  int64  
 6   NumCreditLines   255347 non-null  int64  
 7   InterestRate     255347 non-null  float64
 8   LoanTerm         255347 non-null  int64  
 9   DTIRatio         255347 non-null  float64
 10  Education        255347 non-null  object 
 11  EmploymentType   255347 non-null  object 
 12  MaritalStatus    255347 non-null  object 
 13  HasMortgage      255347 non-null  object 
 14  HasDependents    255347 non-null  object 
 15  LoanPurpose      255347 non-null  object 
 16  HasCoSigner      255347 non-null  object 
 17  Default          255347 non-null  int64  
dtypes: float64(2), int64(8), object(8)
memory usage: 35.1+ MB
```

2.4. Mô tả các thuộc tính

Tập dữ liệu gồm các thuộc tính được chia thành các nhóm chính sau, phản ánh các khía cạnh liên quan đến rủi ro tín dụng:

(1) Nhóm đặc trưng nhân khẩu học

Mô tả thông tin nền tảng và bối cảnh xã hội của khách hàng, bao gồm:

- *Age:* độ tuổi tại thời điểm vay, phản ánh ổn định thu nhập và kinh nghiệm nghề nghiệp
- *Education:* trình độ học vấn, liên quan đến khả năng tiếp cận việc làm ổn định và thu nhập dài hạn
- *EmploymentType:* loại hình việc làm, đánh giá mức độ ổn định nguồn thu nhập
- *MaritalStatus:* tình trạng hôn nhân, gián tiếp thể hiện trách nhiệm tài chính
- *HasDependents:* có người phụ thuộc tài chính hay không, ảnh hưởng đến áp lực chi tiêu

Nhóm biến này giúp mô hình đánh giá mức độ ổn định xã hội và hành vi tài chính, ảnh hưởng gián tiếp đến rủi ro vỡ nợ.

(2) Nhóm đặc trưng tài chính – tín dụng

Phản ánh trực tiếp năng lực tài chính và lịch sử tín dụng của khách hàng:

- *Income:* thu nhập hàng năm
- *CreditScore:* điểm tín dụng, đánh giá uy tín tín dụng
- *MonthsEmployed:* số tháng làm việc tại công việc hiện tại
- *NumCreditLines:* số lượng khoản tín dụng hiện tại
- *DTIRatio:* tỷ lệ nợ trên thu nhập

Nhóm này có tác động trực tiếp đến khả năng chi trả và rủi ro tín dụng.

(3) Nhóm đặc trưng liên quan đến khoản vay

Mô tả đặc điểm của khoản vay:

- *LoanAmount:* tổng số tiền vay
- *InterestRate:* lãi suất (%)
- *LoanTerm:* thời hạn vay (tháng)
- *LoanPurpose:* mục đích vay
- *HasMortgage:* có tài sản thế chấp hay không
- *HasCoSigner:* có người đồng ký bảo lãnh hay không

Các thuộc tính này phản ánh gánh nặng tài chính thực tế của khách hàng và ảnh hưởng trực tiếp đến xác suất vỡ nợ.

(4) Biến mục tiêu

- *Default:* trạng thái khoản vay, nhị phân (1 = vỡ nợ, 0 = thanh toán đúng hạn)

(5) Biến định danh

- *LoanID:* mã định danh duy nhất cho mỗi khoản vay

2.5. Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA)

2.5.1. Kiểm tra dữ liệu ban đầu

Nhóm nghiên cứu bắt đầu với việc kiểm tra tổng quan tập dữ liệu, bao gồm kích thước, danh sách các thuộc tính và kiểu dữ liệu tương ứng. Kết quả cho thấy dữ liệu được nạp đúng định dạng và các thuộc tính có kiểu dữ liệu phù hợp, sẵn sàng cho các bước phân tích tiếp theo.

Đồng thời, nhóm cũng tiến hành kiểm tra giá trị thiếu và bản ghi trùng lặp. Kết quả cho thấy tập dữ liệu không có giá trị bị thiếu và không phát hiện bản ghi trùng lặp, phản ánh chất lượng dữ liệu tốt và đáng tin cậy trong giai đoạn khảo sát ban đầu.

```
# Kiểm tra số lượng giá trị thiếu trên từng cột
print("\nThống kê giá trị thiếu:")
print(df.isnull().sum())
```

```
Thống kê giá trị thiếu:
LoanID            0
Age               0
Income            0
LoanAmount        0
CreditScore       0
MonthsEmployed    0
NumCreditLines    0
InterestRate      0
LoanTerm          0
DTIRatio          0
Education         0
EmploymentType    0
MaritalStatus     0
HasMortgage       0
HasDependents     0
LoanPurpose       0
HasCoSigner       0
Default           0
dtype: int64
```

```
# Kiểm tra số lượng giá trị bị trùng lặp
df.duplicated().sum()
```

```
np.int64(0)
```

2.5.2. Phân bố biến mục tiêu

Biến mục tiêu Default được phân tích thông qua biểu đồ cột nhằm quan sát sự phân bố giữa hai lớp khách hàng vỡ nợ và không vỡ nợ. Kết quả thống kê cho thấy nhóm khách hàng không vỡ nợ (0) chiếm tỷ lệ lớn hơn đáng kể so với nhóm khách hàng vỡ nợ (1). Cụ thể, số lượng khách hàng không vỡ nợ là 225.694 mẫu, chiếm khoảng 88,39%, trong khi số lượng khách hàng vỡ nợ là 29.653 mẫu, chiếm khoảng 11,61%.

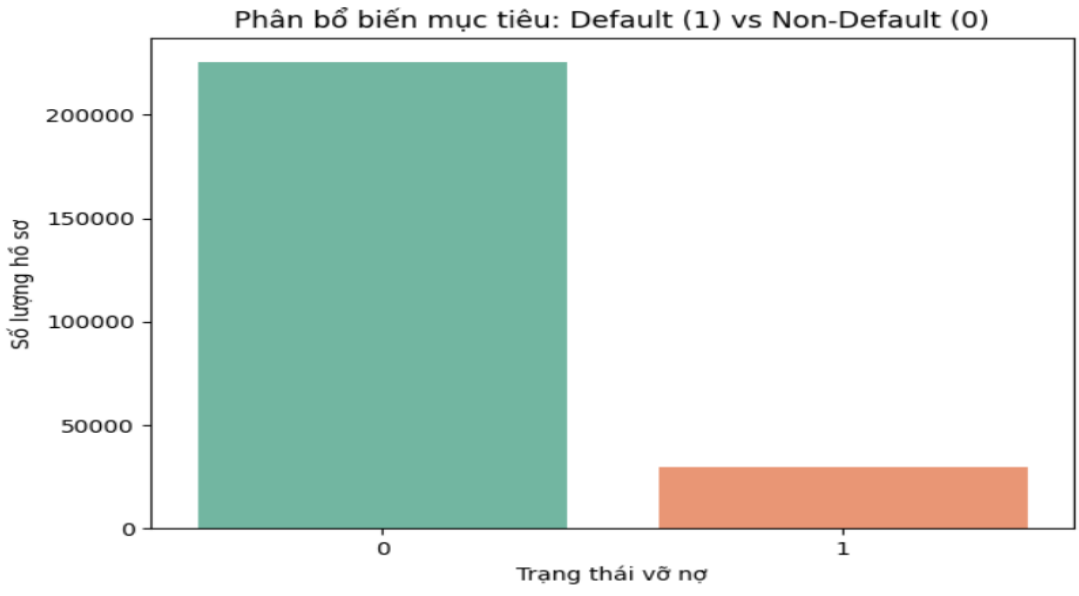
```
# Tỷ lệ biến mục tiêu
# Tính toán tỷ lệ phần trăm các lớp
target_counts = df['Default'].value_counts()
target_percent = df['Default'].value_counts(normalize=True) * 100

print(f"Số lượng khách hàng từng nhóm:\n{target_counts}")
print(f"\nTỷ lệ phần trăm (%):\n{target_percent}")

# Trực quan hóa
plt.figure(figsize=(7, 5))
sns.countplot(x='Default', data=df, palette='Set2')
plt.title('Phân bố biến mục tiêu: Default (1) vs Non-Default (0)')
plt.xlabel('Trạng thái vỡ nợ')
plt.ylabel('Số lượng hồ sơ')
plt.show()
```

```
Số lượng khách hàng từng nhóm:
Default
0    225694
1     29653
Name: count, dtype: int64

Tỷ lệ phần trăm (%):
Default
0    88.387175
1    11.612825
Name: proportion, dtype: float64
```



III. QUY TRÌNH XỬ LÍ DỮ LIỆU

Trước khi tiến hành xây dựng mô hình dự báo, dữ liệu phải được xử lý và chuẩn hóa nhằm đảm bảo chất lượng đầu vào và hạn chế sai lệch trong quá trình học máy.

3.1. Xóa cột không cần thiết

Cột LoanID được loại bỏ vì chỉ là mã định danh duy nhất cho từng khoản vay, không mang thông tin dự đoán. Giữ lại biến này có thể khiến mô hình ghi nhớ dữ liệu thay vì học quy luật (overfitting) và làm sai lệch kết quả. Việc loại bỏ giúp mô hình học các mối quan hệ thực sự trong dữ liệu, giảm nhiễu và cải thiện khả năng tổng quát hóa.

```
# Drop cột LoanID
df = df.drop(columns = ['LoanID'])
```

```
print(f"Số lượng cột: {df.shape[1]}")
```

```
Số lượng cột: 17
```

```
df.columns
```

```
Index(['Age', 'Income', 'LoanAmount', 'CreditScore', 'MonthsEmployed',
       'NumCreditLines', 'InterestRate', 'LoanTerm', 'DTIRatio', 'Education',
       'EmploymentType', 'MaritalStatus', 'HasMortgage', 'HasDependents',
       'LoanPurpose', 'HasCoSigner', 'Default'],
      dtype='object')
```

3.2. Mã hóa biến phân loại

Tiếp theo, các biến phân loại như Education, EmploymentType, MaritalStatus, HasMortgage, HasDependents, LoanPurpose và HasCoSigner được chuyển đổi sang dạng số để phù hợp với yêu cầu xử lý của mô hình. Sử dụng phương pháp mã hóa One-Hot đối với các biến không mang tính thứ bậc, nhằm tránh việc hình thành mối quan hệ giả tạo giữa các nhãn phân loại. Cách tiếp cận này giúp mô hình tiếp nhận thông tin đúng bản chất và tăng khả năng diễn giải kết quả.

```
categorical_cols = df.select_dtypes(include=['object']).columns
df_encoded = pd.get_dummies(df, columns=categorical_cols, drop_first=True)

mapping = []

for col in categorical_cols:
    new_cols = [c for c in df_encoded.columns if c.startswith(col + "_")]
    mapping.append({
        "Cột gốc": col,
        "Các cột sau khi One-Hot Encoding": ", ".join(new_cols)
    })

mapping_df = pd.DataFrame(mapping)

mapping_df
```

Các biến phân loại đã được biến đổi thành nhiều biến nhị phân thông qua One-Hot Encoding, trong đó mỗi cột mới đại diện cho một giá trị cụ thể của biến gốc.

index	Cột gốc	Các cột sau khi One-Hot Encoding
0	Education	Education_High School, Education_Master's, Education_PhD
1	EmploymentType	EmploymentType_Part-time, EmploymentType_Self-employed, EmploymentType_Unemployed
2	MaritalStatus	MaritalStatus_Married, MaritalStatus_Single
3	HasMortgage	HasMortgage_Yes
4	HasDependents	HasDependents_Yes
5	LoanPurpose	LoanPurpose_Business, LoanPurpose_Education, LoanPurpose_Home, LoanPurpose_Other
6	HasCoSigner	HasCoSigner_Yes

Show 25 per page

Sau khi áp dụng mã hóa One-Hot cho các biến phân loại, số lượng cột tăng từ 17 lên 25 cột. Điều này xảy ra vì mỗi giá trị trong biến phân loại được chuyển thành một cột nhị phân riêng. Việc mở rộng số chiều giúp mô hình học máy xử lý dữ liệu phân loại chính xác hơn, tránh việc hiểu sai chúng như các biến số thông thường.

```
rows, cols = df_encoded.shape
print(f"Số dòng sau xử lý: {rows}")
print(f"Số cột sau xử lý: {cols}")
```

```
Số dòng sau xử lý: 255347
Số cột sau xử lý: 25
```

3.3. Chia tập dữ liệu

Sau khi hoàn thiện giai đoạn tiền xử lý, tập dữ liệu được chia thành hai phần độc lập: tập huấn luyện (training set) và tập kiểm tra (test set). Tập huấn luyện chiếm phần lớn dữ liệu và được sử dụng để mô hình học các mối quan hệ giữa các đặc trưng và biến mục tiêu. Ngược lại, tập kiểm tra được giữ tách biệt hoàn toàn trong suốt quá trình xây dựng và tinh chỉnh mô hình, chỉ được sử dụng ở bước đánh giá cuối cùng.

Việc chia tách dữ liệu được thực hiện theo tỷ lệ thông dụng 80% cho huấn luyện và 20% cho kiểm tra, đồng thời bảo toàn tỷ lệ phân phối của biến mục tiêu giữa hai tập dữ liệu. Cách tiếp cận này giúp đảm bảo rằng hiệu suất mô hình phản ánh đúng khả năng tổng quát hóa trên dữ liệu mới, đồng thời hạn chế nguy cơ đánh giá quá lạc quan do trùng lặp thông tin.

```
from sklearn.model_selection import train_test_split

X = df_encoded.drop('Default', axis=1)
y = df_encoded['Default']

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y          # giữ đúng tỷ lệ lớp
)
```

3.4. Chuẩn hóa dữ liệu

Các biến số được chuẩn hóa bằng phương pháp StandardScaler sau khi dữ liệu được chia thành hai tập train–test. Bộ chuẩn hóa đã được huấn luyện trên tập huấn luyện để học giá trị trung bình và độ lệch chuẩn, sau đó được áp dụng cho cả tập train và test. Cách làm này giúp tránh hiện tượng rò rỉ dữ liệu, đồng thời đảm bảo các biến số có cùng thang đo, từ đó hỗ trợ mô hình học tốt hơn và ổn định hơn.

```
# Xác định cột số (không bao gồm biến mục tiêu)
numeric_cols = X_train.select_dtypes(include=['int64', 'float64']).columns

scaler = StandardScaler()

# Fit scaler trên tập train
X_train[numeric_cols] = scaler.fit_transform(X_train[numeric_cols])

# Transform trên tập test
X_test[numeric_cols] = scaler.transform(X_test[numeric_cols])
```

3.5. Xử lý mất cân bằng dữ liệu

Một đặc điểm đáng chú ý của tập dữ liệu là sự mất cân bằng rõ rệt giữa hai nhóm khách hàng: nhóm thanh toán đúng hạn và nhóm vỡ nợ. Tỷ lệ khách hàng thực sự xảy ra vỡ nợ chỉ chiếm một phần nhỏ so với tổng thể, phản ánh đúng đặc trưng của hoạt động tín dụng trong thực tế. Tuy nhiên, sự mất cân bằng này có thể khiến mô hình thiên lệch theo hướng ưu tiên dự đoán lớp đa số, dẫn đến việc bỏ sót các trường hợp rủi ro cao.

```
Tỷ lệ phần trăm (%):
Default
0    88.387175
1    11.612825
Name: proportion, dtype: float64
```

Để khắc phục, nghiên cứu lựa chọn phương pháp truyền trọng số lớp (class weight). Cụ thể, thay vì can thiệp trực tiếp vào dữ liệu bằng cách tạo thêm quan sát giả (như SMOTE), phương pháp này điều chỉnh hàm mất mát của mô hình theo hướng "phạt nặng hơn" đối với các trường hợp dự đoán sai lớp thiểu số. Trọng số được tính tự động dựa trên phân bố y_train, nhờ đó đảm bảo tính khách quan và tránh rò rỉ dữ liệu từ tập kiểm tra. Cách tiếp cận này giúp mô hình cân bằng giữa hai mục tiêu: duy trì cấu trúc dữ liệu gốc và cải thiện khả năng nhận diện các trường hợp vỡ nợ.

```python
from sklearn.utils.class_weight import compute_class_weight
import numpy as np

# Tính trọng số lớp dựa trên y_train
class_weights = compute_class_weight(
    class_weight='balanced',
    classes=np.unique(y_train),
    y=y_train
)

# Chuyển về dạng dictionary để dùng cho mô hình
class_weights = dict(zip(np.unique(y_train), class_weights))

print("Class weights:", class_weights)
```

```
Class weights: {np.int64(0): np.float64(0.5656918944365983), np.int64(1): np.float64(4.30564454936346)}
```

IV. XÂY DỰNG, HUẤN LUYỆN MÔ HÌNH DỰ ĐOÁN

4.1. Quy trình xây dựng mô hình dự đoán vỡ nợ

Quy trình xây dựng mô hình dự đoán khả năng vỡ nợ được thực hiện theo các bước từ chuẩn bị dữ liệu đến huấn luyện và dự đoán, đảm bảo tính khoa học và khả năng ứng dụng thực tiễn:

1) *Chuẩn bị dữ liệu:* Sau khi tiền xử lý, lựa chọn đặc trưng, dữ liệu được chia thành tập huấn luyện và tập kiểm tra.
2) *Huấn luyện mô hình:* Mỗi mô hình học máy được huấn luyện độc lập trên cùng tập huấn luyện, học mối quan hệ giữa các đặc trưng đầu vào và nhãn mục tiêu.
3) *Dự đoán nhãn:* Các mô hình dự đoán khả năng vỡ nợ trên tập kiểm tra, cung cấp cơ sở để đánh giá hiệu quả và phân tích sâu hơn.

Ý nghĩa thực tiễn: Việc triển khai đồng thời ba mô hình giúp so sánh hiệu quả phát hiện khách hàng rủi ro và lựa chọn mô hình phù hợp nhất cho ngân hàng.

4.2. Khởi tạo và huấn luyện mô hình

(1) Logistic Regression

Mô hình Logistic Regression được khởi tạo với tham số class_weight = class_weights nhằm xử lý tình trạng mất cân bằng dữ liệu trong bài toán tín dụng, trong đó số lượng khách hàng vỡ nợ chiếm tỷ lệ nhỏ so với khách hàng thanh toán đúng hạn. Việc gán trọng số cao hơn cho lớp vỡ nợ giúp mô hình chú trọng hơn đến việc phát hiện các trường hợp rủi ro, qua đó giảm nguy cơ bỏ sót khách hàng vỡ nợ (False Negative).

Tham số max_iter = 1000 được thiết lập để tăng số vòng lặp tối đa trong quá trình tối ưu, đảm bảo mô hình hội tụ ổn định khi huấn luyện trên tập dữ liệu có kích thước lớn và nhiều đặc trưng.

Sau khi khởi tạo, mô hình được huấn luyện bằng phương thức fit(X_train, y_train), trong đó mô hình học mối quan hệ giữa các biến đầu vào và nhãn mục tiêu nhằm ước lượng xác suất khách hàng vỡ nợ dựa trên dữ liệu huấn luyện.

```
# Khởi tạo mô hình
lr_model = LogisticRegression(class_weight= class_weights, max_iter=1000)

# Huấn luyện mô hình
lr_model.fit(X_train, y_train)
```

(2) Random Forest

Mô hình Random Forest là một phương pháp học tập tổ hợp (Ensemble Learning), trong đó nhiều cây quyết định được huấn luyện độc lập và kết hợp để đưa ra dự đoán cuối cùng. Cách tiếp cận này giúp giảm phương sai và cải thiện khả năng tổng quát hóa so với việc sử dụng một cây đơn lẻ.

Trong quá trình khởi tạo, các tham số quan trọng được thiết lập gồm: n_estimators = 200 (số lượng cây, giúp mô hình ổn định và giảm overfitting), max_depth = 12 (giới hạn độ sâu mỗi cây để kiểm soát độ phức tạp), random_state = 42 (đảm bảo kết quả tái lập được) và class_weight = class_weights (xử lý mất cân bằng dữ liệu, ưu tiên lớp khách hàng vỡ nợ).

Sau khi khởi tạo, mô hình được huấn luyện thông qua phương thức fit(X_train, y_train). Trong quá trình này, mỗi cây quyết định được huấn luyện trên một tập mẫu ngẫu nhiên (bootstrap) của dữ liệu huấn luyện và tại mỗi nút chỉ xem xét một tập con ngẫu nhiên các biến. Cơ chế này tăng tính đa dạng giữa các cây, nâng cao hiệu quả dự đoán và khả năng xử lý các mối quan hệ phi tuyến trong dữ liệu tín dụng.

```
# Khởi tạo mô hình
rf_model = RandomForestClassifier(
    n_estimators= 200,
    max_depth= 12,
    random_state=42,
    class_weight = class_weights
)

# Huấn luyện mô hình
rf_model.fit(X_train, y_train)
```

(3) XGBoost

Mô hình XGBoost (Extreme Gradient Boosting) được sử dụng để khai thác các mối quan hệ phi tuyến phức tạp và nâng cao hiệu suất dự đoán trong bài toán vỡ nợ. Trước khi khởi tạo, nghiên

cứu tính toán tỷ lệ mất cân bằng giữa hai lớp trong tập huấn luyện, từ đó xác định scale_ratio để điều chỉnh trọng số lớp, giúp mô hình tập trung hơn vào việc phát hiện khách hàng rủi ro.

Các tham số chính khi khởi tạo gồm: n_estimators = 200 (số lượng cây), learning_rate = 0.1 (tốc độ học, hạn chế overfitting), max_depth = 6 (giới hạn độ sâu mỗi cây), scale_pos_weight = scale_ratio (xử lý mất cân bằng lớp), random_state = 42 (đảm bảo kết quả tái lập), cùng với use_label_encoder = False và eval_metric = 'logloss' (tương thích với thư viện XGBoost cho bài toán phân loại nhị phân).

Sau khi khởi tạo, mô hình được huấn luyện bằng fit(X_train, y_train). Trong quá trình này, các cây quyết định được xây dựng tuần tự, mỗi cây mới học và sửa những sai số của cây trước đó theo cơ chế gradient boosting. Cách tiếp cận này giúp XGBoost tối ưu đồng thời độ lệch và phương sai, nâng cao khả năng phân biệt giữa khách hàng thanh toán đúng hạn và khách hàng vỡ nợ.

```
# Tính toán tỷ lệ cân bằng
count_non_default = np.sum(y_train == 0)
count_default = np.sum(y_train == 1)
scale_ratio = count_non_default / count_default

# Khởi tạo mô hình
xgb_model = XGBClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=6,
    scale_pos_weight=scale_ratio,
    random_state=42,
    use_label_encoder=False,
    eval_metric='logloss'
)

# Huấn luyện mô hình
xgb_model.fit(X_train, y_train)
```

4.3. Dự đoán nhãn vỡ nợ

Sau khi hoàn tất quá trình huấn luyện, ba mô hình Logistic Regression, Random Forest và XGBoost được sử dụng để dự đoán khả năng vỡ nợ của khách hàng trên tập kiểm tra. Biến mục tiêu y được mã hóa nhị phân: 0 đại diện cho khách hàng không vỡ nợ và 1 đại diện cho khách hàng vỡ nợ.

Logistic Regression dự đoán dựa trên mối quan hệ tuyến tính giữa các đặc trưng đầu vào và xác suất vỡ nợ. Khi đầu ra là 1, mô hình nhận định khách hàng có nguy cơ vỡ nợ; khi đầu ra là 0, khách hàng được dự đoán không vỡ nợ.

```
# Dự đoán mô hình
y_pred_lr = lr_model.predict(X_test)
```

Random Forest dựa trên cơ chế tập hợp nhiều cây quyết định. Mỗi khách hàng được phân loại dựa trên bỏ phiếu đa số của các cây trong rừng, giúp giảm phương sai và nâng cao khả năng tổng quát hóa. Giá trị dự đoán 1 thể hiện khách hàng có nguy cơ vỡ nợ, giá trị 0 thể hiện không vỡ nợ.

```
# Dự đoán mô hình
y_pred_rf = rf_model.predict(X_test)
```

XGBoost sử dụng cơ chế boosting, trong đó các cây quyết định được xây dựng tuần tự, mỗi cây mới học và sửa các sai sót của cây trước đó. Cách tiếp cận này giúp mô hình tập trung phát hiện lớp thiểu số – khách hàng vỡ nợ. Tương tự, giá trị 1 đại diện cho khách hàng có nguy cơ vỡ nợ, giá trị 0 đại diện cho khách hàng không vỡ nợ.

```
# Dự đoán mô hình
y_pred_xgb = xgb_model.predict(X_test)
```

Bước dự đoán này cung cấp kết quả phân loại cuối cùng cho từng mô hình, làm cơ sở để so sánh hiệu quả giữa các mô hình, đánh giá khả năng nhận diện khách hàng vỡ nợ và phân tích sâu hơn trong các bước tiếp theo, bao gồm đánh giá mô hình, lựa chọn mô hình tối ưu và giải thích bằng các phương pháp giải thích mô hình (XAI).

V. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

5.1. Minh họa kết quả dự đoán

(1) LOGISTIS REGRESSION

```
LOGISTIC REGRESSION

Số mẫu test: 51070

BẢNG SO SÁNH THỰC TẾ VỚI DỰ ĐOÁN:
   Thực tế  Dự đoán  Xác suất vỡ nợ
0        0        0        0.186358
1        0        0        0.140203
2        0        0        0.378181
3        0        1        0.569233
4        0        0        0.407138
5        0        0        0.068914
6        0        1        0.804479
7        0        0        0.368180
8        1        1        0.795809
9        0        1        0.593022

Ma trận nhầm lẫn:
 [[30393 14746]
 [ 1781  4150]]

Báo cáo phân loại:
              precision    recall  f1-score   support

           0       0.94      0.67      0.79     45139
           1       0.22      0.70      0.33      5931

    accuracy                           0.68     51070
   macro avg       0.58      0.69      0.56     51070
weighted avg       0.86      0.68      0.73     51070
```

Mô hình Logistic Regression được áp dụng để dự đoán khả năng vỡ nợ của khách hàng. Tập kiểm tra có 51.070 mẫu.

- Nhiều khách hàng không vỡ nợ được dự đoán đúng (0 → 0).
- Một số khách hàng thực tế không vỡ nợ bị dự đoán là vỡ nợ (0 → 1), đây là False Positive.
- Một số khách hàng thực tế vỡ nợ được mô hình dự đoán đúng (1 → 1), nhưng vẫn còn False Negative.

Ma trận nhầm lẫn:

- Mô hình nhận biết được 4.150/5.931 khách hàng vỡ nợ, tương đương Recall ≈ 0.70, tức là khả năng phát hiện khách hàng rủi ro khá tốt.
- Mô hình bị báo động giả nhiều (14.746 khách), nhưng trong bài toán tín dụng, việc cảnh báo nhiều hơn là chấp nhận được để giảm nguy cơ bỏ sót rủi ro.

Các chỉ số phân loại:

- Precision (lớp 1): 0.22 → Trong số các khách hàng dự đoán là vỡ nợ, chỉ 22% thực sự vỡ nợ.

- Recall (lớp 1): 0.70 → Mô hình phát hiện 70% khách hàng thực sự vỡ nợ.
- F1-score (lớp 1): 0.33 → Là giá trị cân bằng giữa Precision và Recall.
- Accuracy: 0.68 → Tỷ lệ dự đoán đúng tổng thể.

Nhận xét: Mô hình ưu tiên phát hiện khách hàng vỡ nợ (Recall cao), phù hợp với mục tiêu giảm nguy cơ bỏ sót rủi ro tín dụng. Precision thấp là chấp nhận được trong bối cảnh này, vì cảnh báo sai còn tốt hơn bỏ sót khách hàng rủi ro.

(2) RANDOM FOREST

```
RANDOM FOREST

Số mẫu test: 51070

BẢNG SO SÁNH THỰC TẾ VỚI DỰ ĐOÁN:
   Thực tế  Dự đoán  Xác suất vỡ nợ
0        0        0        0.236015
1        0        0        0.203323
2        0        0        0.296330
3        0        0        0.366880
4        0        0        0.286104
5        0        0        0.112797
6        0        1        0.668562
7        0        0        0.273990
8        1        1        0.609154
9        0        1        0.532128

Ma trận nhầm lẫn:
 [[36417  8722]
 [ 2676  3255]]

Báo cáo phân loại:
              precision    recall  f1-score   support

           0       0.93      0.81      0.86     45139
           1       0.27      0.55      0.36      5931

    accuracy                           0.78     51070
   macro avg       0.60      0.68      0.61     51070
weighted avg       0.85      0.78      0.81     51070
```

- Hầu hết khách hàng không vỡ nợ được dự đoán đúng (0 → 0).
- Một số khách hàng thực tế không vỡ nợ bị dự đoán là vỡ nợ (0 → 1, False Positive).
- Một số khách hàng thực tế vỡ nợ được dự đoán đúng (1 → 1), nhưng vẫn còn False Negative.

Ma trận nhầm lẫn:

- Mô hình phát hiện được 3.255/5.931 khách hàng vỡ nợ, tương đương Recall ≈ 0.55.

- Số lượng báo động giả (0 → 1) là 8.722, ít hơn so với Logistic Regression, nghĩa là mô hình này thận trọng hơn khi dự đoán khách vỡ nợ.

Các chỉ số phân loại:

- Precision (lớp 1): 0.27 → Trong số các khách hàng dự đoán là vỡ nợ, 27% thực sự vỡ nợ.
- Recall (lớp 1): 0.55 → Mô hình phát hiện 55% khách hàng thực sự vỡ nợ.
- F1-score (lớp 1): 0.36 → Là giá trị cân bằng giữa Precision và Recall.
- Accuracy: 0.78 → Tỷ lệ dự đoán đúng tổng thể cao hơn so với Logistic Regression.

Nhận xét: Random Forest tăng tỷ lệ dự đoán đúng tổng thể (Accuracy) nhờ khả năng học quan hệ phi tuyến. Tuy nhiên, khả năng phát hiện khách vỡ nợ (Recall) thấp hơn Logistic Regression, nên mô hình này thận trọng hơn, giảm cảnh báo giả nhưng cũng bỏ sót nhiều khách rủi ro hơn. Mô hình phù hợp nếu mục tiêu là cân bằng giữa phát hiện rủi ro và tránh cảnh báo sai quá nhiều.

(3) XGBOOST

```
XGBOOST CLASSIFICATION

Số mẫu test: 51070

BẢNG SO SÁNH THỰC TẾ VỚI DỰ ĐOÁN:
   Thực tế  Dự đoán  Xác suất vỡ nợ
0        0        0        0.262093
1        0        0        0.044395
2        0        0        0.226542
3        0        0        0.411162
4        0        0        0.317044
5        0        0        0.048481
6        0        1        0.711967
7        0        0        0.212244
8        1        1        0.740705
9        0        1        0.625524

Ma trận nhầm lẫn:
 [[32575 12564]
 [ 2108  3823]]

Báo cáo phân loại:
              precision    recall  f1-score   support

           0       0.94      0.72      0.82     45139
           1       0.23      0.64      0.34      5931

    accuracy                           0.71     51070
   macro avg       0.59      0.68      0.58     51070
weighted avg       0.86      0.71      0.76     51070
```

- Hầu hết khách hàng không vỡ nợ được dự đoán đúng (0 → 0).
- Một số khách hàng thực tế không vỡ nợ bị dự đoán là vỡ nợ (0 → 1, False Positive).
- Một phần khách hàng thực tế vỡ nợ được phát hiện đúng (1 → 1), còn lại là False Negative.

Ma trận nhầm lẫn:

- Mô hình phát hiện được 3.823/5.931 khách hàng vỡ nợ, tương đương Recall ≈ 0.64.
- Số lượng báo động giả (0 → 1) là 12.564, cao hơn Random Forest, nghĩa là mô hình XGBoost cảnh báo nhiều hơn, tập trung vào phát hiện khách rủi ro.

Các chỉ số phân loại

- Precision (lớp 1): 0.23 → Trong số các khách dự đoán vỡ nợ, 23% thực sự vỡ nợ.
- Recall (lớp 1): 0.64 → Mô hình phát hiện 64% khách hàng thực sự vỡ nợ, cao hơn Logistic Regression và Random Forest.
- F1-score (lớp 1): 0.34 → Là giá trị cân bằng giữa Precision và Recall.
- Accuracy: 0.71 → Tỷ lệ dự đoán đúng tổng thể thấp hơn Random Forest, nhưng tập trung hơn vào phát hiện rủi ro.

Nhận xét: XGBoost tăng Recall cho lớp khách vỡ nợ, nghĩa là mô hình nhạy hơn trong việc phát hiện rủi ro. Tuy nhiên, số cảnh báo giả tăng dẫn đến Precision thấp. Phù hợp nếu mục tiêu là phát hiện tối đa khách rủi ro, chấp nhận tăng số cảnh báo sai để giảm bỏ sót khách vỡ nợ.

5.2. Đánh giá mô hình

Sau khi huấn luyện và dự đoán, các mô hình được đánh giá dựa trên các chỉ số quan trọng: Accuracy, Precision, Recall, F1-score và ROC-AUC. Việc đánh giá này giúp so sánh hiệu quả nhận diện khách hàng vỡ nợ giữa các mô hình và xác định mô hình phù hợp nhất cho bài toán.

BẢNG TỔNG HỢP KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH:

	Mô hình	Accuracy	Precision	Recall	F1-Score	ROC-AUC
0	Logistic Regression	0.68	0.22	0.70	0.33	0.75
1	Random Forest	0.78	0.27	0.55	0.36	0.75
2	XGBoost	0.71	0.23	0.64	0.34	0.75

MÔ HÌNH PHÙ HỢP NHẤT: Logistic Regression

- *Accuracy:* Random Forest có Accuracy cao nhất (0.78), nhưng Accuracy không phản ánh đầy đủ hiệu quả trên lớp thiểu số (khách vỡ nợ).
- *Recall:* Logistic Regression có Recall cao nhất (0.70), tức là phát hiện nhiều khách hàng vỡ nợ hơn, phù hợp với mục tiêu quản trị rủi ro.
- *Precision:* Tất cả mô hình có Precision thấp (~0.22–0.27) do lớp vỡ nợ chiếm tỷ lệ nhỏ trong dữ liệu, dẫn đến nhiều cảnh báo giả.
- *F1-Score*: Kết hợp giữa Precision và Recall, cho thấy Logistic Regression và XGBoost cân bằng hơn trong việc phát hiện khách vỡ nợ.
- *ROC-AUC*: Cả ba mô hình đều đạt 0.75, cho thấy khả năng phân biệt giữa hai lớp tương đối giống nhau.

Chọn mô hình tối ưu:

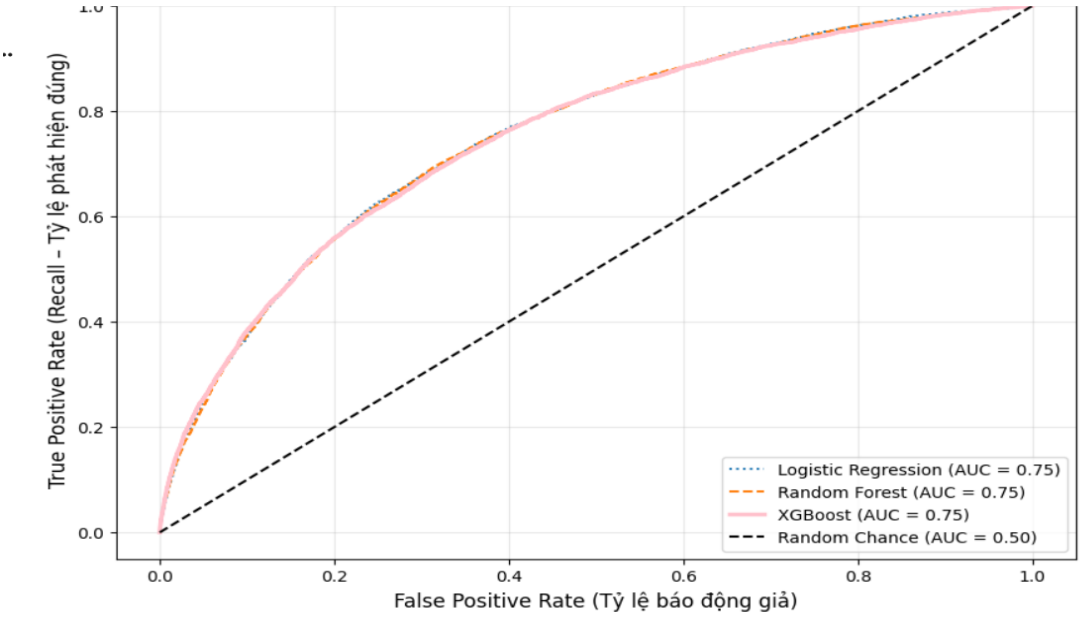
Sau khi so sánh các chỉ số đánh giá, việc lựa chọn mô hình tối ưu không chỉ dựa vào Accuracy, mà tập trung vào khả năng phát hiện khách hàng vỡ nợ (lớp thiểu số) vì đây là mục tiêu quan trọng trong quản trị rủi ro tín dụng.

- *Recall (Tỷ lệ phát hiện đúng khách vỡ nợ):* Logistic Regression đạt Recall cao nhất (0.70), nghĩa là trong tổng số 5,931 khách hàng vỡ nợ trong tập test, mô hình này phát hiện được khoảng 70%. Trong khi đó, Random Forest chỉ đạt 0.55 và XGBoost đạt 0.64. Việc Recall cao giúp giảm tối đa False Negative, tức là giảm nguy cơ bỏ sót khách hàng vỡ nợ, điều cực kỳ quan trọng trong tín dụng.

- *ROC-AUC (Khả năng phân biệt lớp):* Cả ba mô hình đều có ROC-AUC bằng 0.75, cho thấy khả năng phân biệt giữa khách hàng thanh toán đúng hạn và khách hàng vỡ nợ tương đối giống nhau. Tuy nhiên, khi kết hợp với Recall, Logistic Regression nổi bật hơn, vì nó vừa có khả năng phân biệt tốt vừa phát hiện được nhiều khách vỡ nợ nhất.

- *Precision (Độ chính xác dự đoán khách vỡ nợ):* Mặc dù Precision của Logistic Regression thấp (0.22), điều này đồng nghĩa với việc một số cảnh báo giả vẫn xảy ra (khách dự đoán vỡ nợ nhưng thực tế không vỡ). Tuy nhiên, trong bối cảnh quản trị rủi ro, phát hiện đủ khách vỡ nợ quan trọng hơn so với cảnh báo giả, do hậu quả của việc bỏ sót khách vỡ nợ nghiêm trọng hơn nhiều.

Kết luận: Với mục tiêu tối ưu phát hiện rủi ro tín dụng, Logistic Regression được chọn làm mô hình tối ưu, vì nó cân bằng giữa khả năng phát hiện khách vỡ nợ và khả năng phân biệt giữa các lớp.



Đường cong ROC cung cấp hình ảnh trực quan về hiệu quả phân loại của từng mô hình:

- Trục **x**: False Positive Rate (Tỷ lệ cảnh báo giả)
- Trục **y**: True Positive Rate = Recall (Tỷ lệ phát hiện đúng khách vỡ nợ)

Nhận xét chi tiết:

1.Logistic Regression (nét chấm)

○ Có đường cong nằm cao hơn gần khu vực Recall cao, thể hiện khả năng phát hiện khách vỡ nợ tốt hơn.
AUC = 0.75, vượt xa đường ngẫu nhiên (AUC = 0.50), chứng tỏ mô hình phân biệt hiệu quả.

2.Random Forest (nét gạch)

○ Có đường cong ổn định, nhưng thấp hơn Logistic Regression ở khu vực Recall cao.

○ Điều này giải thích vì sao Recall chỉ đạt 0.55.

3.XGBoost (đường màu hồng)

○ Đường cong ROC tương tự Logistic Regression, nhưng ở các mức FPR thấp, độ nhạy không bằng Logistic Regression.

○ AUC = 0.75, nhưng không thể phát hiện nhiều khách vỡ nợ hơn Logistic Regression.

4.*Đường chéo đen – Ngẫu nhiên (Random Chance):* Dùng để so sánh: nếu mô hình có đường cong nằm gần đường chéo, tức là dự đoán không khác gì ngẫu nhiên.

Ý nghĩa trực quan:

- Logistic Regression vượt trội trong việc phát hiện khách hàng vỡ nợ, đặc biệt ở khu vực quan trọng của Recall cao.

- Random Forest và XGBoost có thể dự đoán chính xác hơn một chút trên lớp đa số, nhưng không tối ưu cho mục tiêu rủi ro tín dụng.

5.3. Giải thích mô hình Logistic Regression bằng SHAP(XAI)

Sau khi lựa chọn mô hình Logistic Regression là mô hình tối ưu, nghiên cứu tiến hành giải thích mô hình nhằm minh bạch hóa quyết định dự đoán vỡ nợ. Việc này được thực hiện bằng thư viện SHAP, cụ thể như sau:

```
# Lấy 1 mẫu nhỏ cho SHAP
X_shap = X_train.sample(1000, random_state=42)

# Dùng LinearExplainer cho Logistic Regression
explainer = shap.LinearExplainer(lr_model, X_shap)

# Tính SHAP values
shap_values = explainer.shap_values(X_shap)

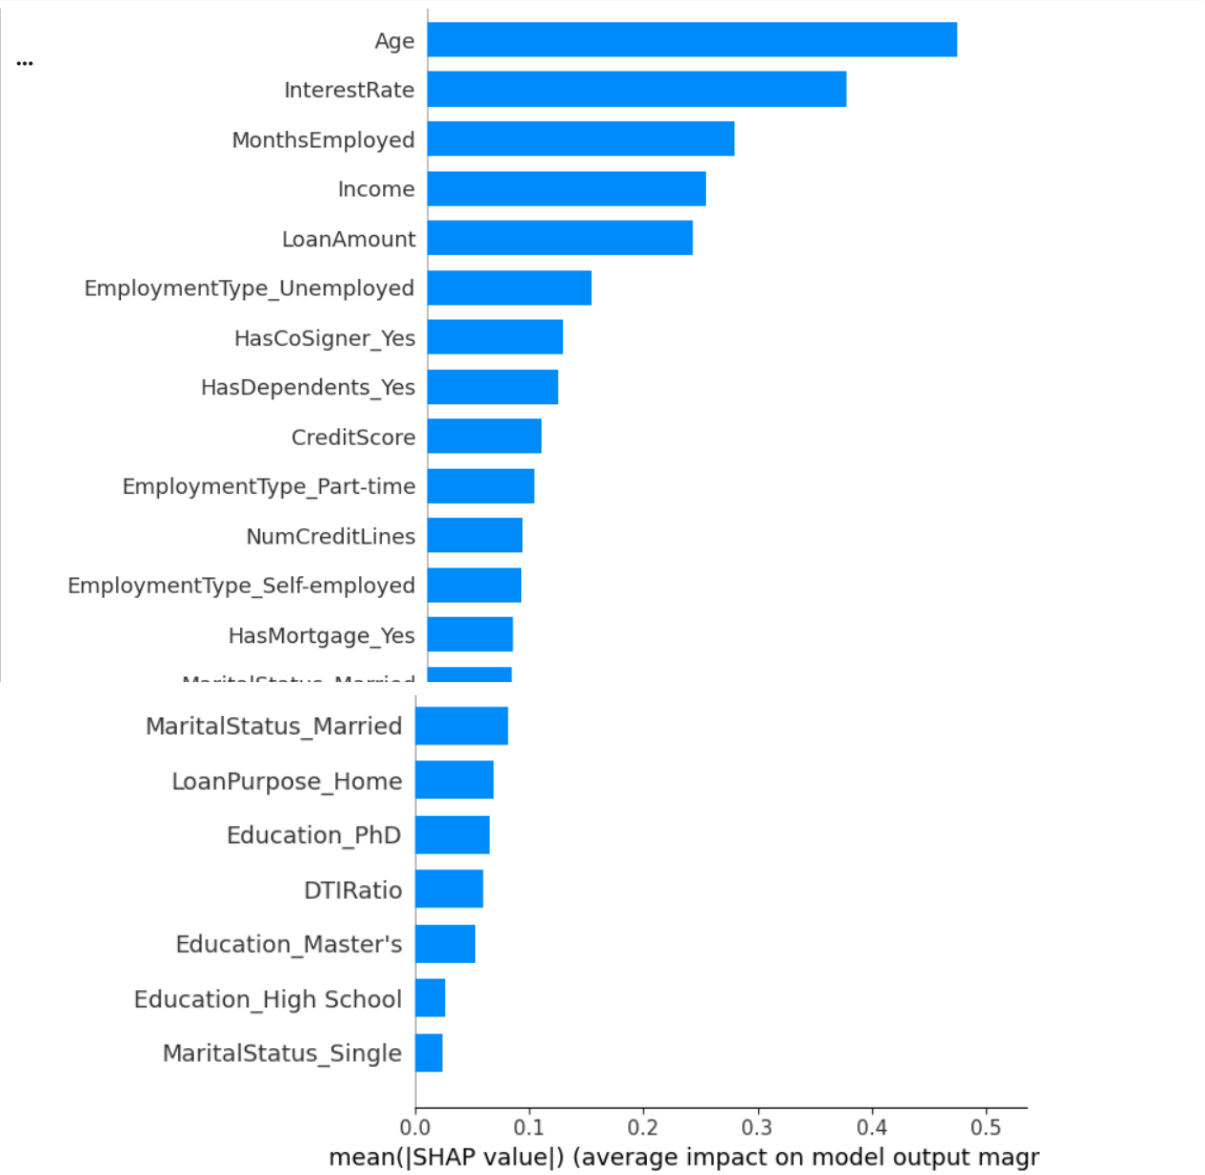
# Summary plot
shap.summary_plot(
    shap_values,
    X_shap,
    feature_names=X_shap.columns,
    plot_type="bar"
)
```

1.***Chọn dữ liệu nền*:** Một mẫu nhỏ gồm 1000 khách hàng được lấy từ tập huấn luyện (X_train) để làm dữ liệu nền, giúp SHAP tính toán nhanh hơn và vẫn phản ánh đặc điểm chung của tập dữ liệu.

2.***Tạo explainer*:** LinearExplainer được sử dụng vì Logistic Regression là mô hình tuyến tính. Explainer sẽ tính toán SHAP values, thể hiện mức độ ảnh hưởng của từng biến đến dự đoán của mô hình.

3.***Tính SHAP values*:** SHAP values được tính cho các mẫu dữ liệu nền, kết quả cho thấy biến nào đóng góp tích cực hay tiêu cực vào xác suất vỡ nợ. Giá trị tuyệt đối của SHAP value phản ánh tầm quan trọng tương đối của biến đó.

4.***Trực quan hóa bằng summary plot*:** Biểu đồ tóm tắt dạng bar chart hiển thị mức độ ảnh hưởng trung bình tuyệt đối của từng biến. Các biến được sắp xếp theo thứ tự giảm dần, giúp nhận diện các yếu tố quan trọng nhất trong quyết định dự đoán.



Nhận xét mô hình: Kết quả phân tích SHAP cho mô hình Logistic Regression cho thấy các biến tài chính và đặc điểm liên quan trực tiếp đến khoản vay đóng vai trò chi phối trong việc xác định xác suất vỡ nợ của khách hàng:

- Biến Age có mức độ ảnh hưởng lớn nhất đến kết quả dự đoán, cho thấy độ tuổi là yếu tố quan trọng trong đánh giá rủi ro tín dụng. Điều này phản ánh thực tế rằng độ tuổi có mối liên hệ chặt chẽ với mức độ ổn định nghề nghiệp, thu nhập và kinh nghiệm tài chính của khách hàng.
- Các biến InterestRate, MonthsEmployed, Income và LoanAmount cũng có mức độ ảnh hưởng đáng kể. Cụ thể, lãi suất cao, thời gian làm việc ngắn, thu nhập thấp hoặc khoản vay có giá trị lớn đều làm gia tăng xác suất vỡ nợ, phù hợp với logic tài chính và các nguyên tắc quản trị rủi ro tín dụng trong thực tiễn.

- Nhóm biến phản ánh tình trạng việc làm và hỗ trợ tài chính như EmploymentType_Unemployed, EmploymentType_Part-time, EmploymentType_Self-employed và HasCoSigner có mức độ ảnh hưởng trung bình. Các biến này không quyết định trực tiếp nhưng đóng vai trò điều chỉnh xác suất dự đoán, phản ánh mức độ ổn định thu nhập và khả năng giảm thiểu rủi ro thông qua bảo lãnh.
- Ngược lại, các biến nhân khẩu học sau khi mã hóa one-hot như trình độ học vấn (Education) và tình trạng hôn nhân (MaritalStatus) có mức độ ảnh hưởng tương đối thấp. Điều này cho thấy các yếu tố này chỉ đóng vai trò bổ trợ, ít mang tính quyết định so với các biến tài chính cốt lõi trong mô hình Logistic Regression.

Kết luận: Kết quả phân tích SHAP cho thấy mô hình Logistic Regression chủ yếu dựa vào các biến tài chính và đặc điểm khoản vay để dự đoán khả năng vỡ nợ của khách hàng. Các yếu tố như độ tuổi, thu nhập, lãi suất, quy mô khoản vay và mức độ ổn định việc làm có ảnh hưởng lớn nhất đến xác suất vỡ nợ, phù hợp với thực tiễn quản trị rủi ro tín dụng. Việc áp dụng SHAP giúp nâng cao tính minh bạch và khả năng giải thích của mô hình, góp phần tăng độ tin cậy khi triển khai Logistic Regression trong các hệ thống chấm điểm tín dụng tại ngân hàng và fintech.

VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Nghiên cứu đã triển khai ba mô hình học máy giám sát: Logistic Regression, Random Forest và XGBoost để dự đoán khả năng vỡ nợ của khách hàng dựa trên dữ liệu tín dụng gồm 255.000 mẫu và 18 đặc trưng.

Qua quá trình huấn luyện và dự đoán, Logistic Regression được xác định là mô hình tối ưu vì:

- Recall cao nhất (0.70) giúp phát hiện tốt các khách hàng có nguy cơ vỡ nợ – lớp thiểu số quan trọng trong quản trị rủi ro.
- ROC-AUC đồng thời đạt 0.75, thể hiện khả năng phân biệt hai lớp tốt và ổn định.
- Giải thích mô hình bằng SHAP cho thấy các biến tài chính cốt lõi như Age, InterestRate, Income, LoanAmount, MonthsEmployed có tác động mạnh nhất đến xác suất vỡ nợ, phản ánh đúng logic nghiệp vụ tín dụng: khách hàng trẻ tuổi, thu nhập thấp, vay nhiều hoặc thời gian làm việc ngắn dễ có rủi ro.

Mặc dù Random Forest và XGBoost có khả năng học quan hệ phi tuyến và xử lý dữ liệu phức tạp, nhưng nhược điểm là tính minh bạch thấp và độ giải thích kém so với Logistic Regression.

Việc sử dụng class_weight và scale_pos_weight giúp cân bằng dữ liệu, cải thiện khả năng dự đoán lớp thiểu số, giảm nguy cơ bỏ sót khách hàng rủi ro (False Negative).

Nhận xét tổng quan: Mô hình Logistic Regression không chỉ dự đoán hiệu quả mà còn đảm bảo tính giải thích và minh bạch, phù hợp với yêu cầu kiểm soát rủi ro trong ngân hàng. Các mô hình cây (Random Forest, XGBoost) có thể được sử dụng bổ trợ nếu cần tăng khả năng học quan hệ phi tuyến, nhưng cần kết hợp thêm giải thích bằng SHAP hoặc LIME để tăng tính minh bạch.

6.2. Hướng phát triển

(1) Mở rộng và cải thiện dữ liệu đầu vào:

- Thu thập thêm thông tin về lịch sử tín dụng, hành vi tiêu dùng, mức thu nhập biến động và các biến kinh tế vĩ mô.
- Sử dụng feature engineering nâng cao, tạo các biến tổng hợp phản ánh khả năng trả nợ, tỷ lệ nợ trên thu nhập, mức độ ổn định công việc, nhằm tăng sức mạnh dự đoán.

(2) Tối ưu và kết hợp mô hình:

- Triển khai ensemble learning hoặc stacking giữa Logistic Regression và các mô hình cây để cân bằng giữa khả năng dự đoán và giải thích.
- Thử nghiệm các thuật toán boosting hiện đại khác như LightGBM, CatBoost, kết hợp với điều chỉnh trọng số lớp để cải thiện Recall trên lớp thiểu số.

(3) Giải thích và minh bạch mô hình:

- Áp dụng SHAP hoặc LIME cho mô hình phi tuyến để giải thích dự đoán và xây dựng bảng giải thích chi tiết cho từng khách hàng.
- Phát triển dashboard trực quan hiển thị các SHAP values theo từng biến, giúp đội ngũ quản lý tín dụng hiểu rõ yếu tố quyết định rủi ro.

(4) Triển khai thực tiễn và giám sát:

- Tích hợp mô hình vào hệ thống quản lý rủi ro tín dụng ngân hàng, sử dụng dự đoán để hỗ trợ phê duyệt khoản vay, định giá lãi suất hoặc đưa ra cảnh báo sớm.
- Xây dựng quy trình giám sát mô hình định kỳ: đánh giá hiệu quả dự đoán theo thời gian, cập nhật trọng số lớp, huấn luyện lại khi dữ liệu mới có sự thay đổi.

Kết luận chung: Nghiên cứu khẳng định rằng Logistic Regression, khi kết hợp với SHAP và xử lý cân bằng dữ liệu, vừa đảm bảo hiệu quả dự đoán, vừa tăng tính minh bạch và giải thích, là lựa chọn phù hợp trong quản trị rủi ro tín dụng. Đồng thời, hướng phát triển mở ra cơ hội nâng cao mô hình bằng dữ liệu bổ sung, ensemble và giải thích nâng cao, từ đó triển khai ứng dụng thực tiễn trong ngân hàng.

DANH MỤC TÀI LIỆU THAM KHẢO

Bùi Đan Thanh, Võ Thị Thanh Vân, & Nguyễn Ngọc Huyền. (2023). *Dự báo khả năng vỡ nợ của khách hàng cá nhân tại Ngân hàng Nông nghiệp và Phát triển Nông thôn Việt Nam Chi nhánh Tân Phước Khánh – Bình Dương.* Tạp chí Kinh tế và Ngân hàng Châu Á. https://scholar.dlu.edu.vn/thuvienso/bitstream/DLU123456789/195895/1/CVv497S202-2032023098.pdf

GeeksforGeeks. (2025, July 14). *SHAP: A Comprehensive Guide to SHapley Additive exPlanations.* https://www.geeksforgeeks.org/machine-learning/shap-a-comprehensive-guide-to-shapley-additive-explanations/

GeeksforGeeks. (2025, July 31). *EDA - Exploratory Data Analysis in Python*. https://www.geeksforgeeks.org/data-analysis/exploratory-data-analysis-in-python/

GeeksforGeeks. (2025, September 5). *Implementation of XGBoost (eXtreme Gradient Boosting).* https://www.geeksforgeeks.org/machine-learning/implementation-of-xgboost-extreme-gradient-boosting/

GeeksforGeeks. (2025, December 23). *Logistic Regression in Machine Learning.* https://www.geeksforgeeks.org/machine-learning/understanding-logistic-regression/

GeeksforGeeks. (2025, December 23). *Random Forest Algorithm in Machine Learning.* https://www.geeksforgeeks.org/machine-learning/random-forest-algorithm-in-machine-learning/

Nikhil. (n.d.). *Loan Default Prediction Dataset*. Kaggle. https://www.kaggle.com/datasets/nikhil1e9/loan-default